

LLM Final Ödevi

Türkiye Yapay Zeka Akademisi

Konu	Gemma ile On-Prem Chatbot
Ödev Türü	Final Ödevi
Teslim Formatı	Github link

Ödev Açıklaması

Bu final ödevinde, vLLM üzerinde çalışan Gemma modeli ile terminal tabanlı bir chatbot uygulaması geliştirmeniz beklenmektedir. Amaç; on-prem LLM kullanımı, vLLM endpoint bağlantısı, sistem mesajı, model parametreleri, konuşma döngüsü ve hata yönetimi konularını gerçek bir uygulama akışında birleştirmenizdir.

Teslim Kuralları

- Ödevinizi tek bir Python dosyası olarak hazırlayınız.
- Teslim dosya adı şu formatta olmalıdır: AdSoyad_gemma_chatbot.py
- Python dosyanız çalışır durumda olmalı ve gerekli açıklama satırlarını içermelidir.
- Ödevinizi bir GitHub repository içine yükleyiniz.
- Repository içinde en az Python dosyanız, varsa requirements.txt ve kısa bir README.md dosyası bulunmalıdır.
- Teslimi** GitHub repository linkini e-posta ile göndererek yapınız.
- GitHub repository linkinizi **info@turkiyeyapayzekaakademisi.com** adresine iletiniz.
- Mail konusu şu formatta olmalıdır: LLM Final Ödevi – Ad Soyad

Destek ve Mentorluk

- Ödev sürecinde aklınıza takılan soruları her hafta gerçekleştirdiğimiz mentörlük toplantılarında sorabilirsiniz.
- Ödevi yaparken derste işlediğimiz mantığı uygulamanız beklenmektedir; doğrudan kopya çözüm yerine kendi akışınızı kurmanız önemlidir.

Ödev Soruları

- Gemma 3 4B veya Gemma 3 1B modelini vLLM üzerinde çalıştıracak ortamı hazırlayın. Docker container çalıştırma komutunu kod dosyanızın başındaki docstring içinde belirtin.
- Gemma modeline Python üzerinden istek gönderebilen bir chatbot dosyası oluşturun. Dosyanın adı assignment_gemma_chatbot.py olmalıdır.
- vLLM bağlantı bilgilerini .env dosyasından okuyun. base_url, api_key ve model_name değerlerini kod içinde yönetilebilir hale getirin.
- Terminal üzerinden kullanıcıdan mesaj alan bir konuşma döngüsü kurun. Kullanıcı q, quit, exit veya çıkış yazdığında uygulama sonlansın.

5. Sistem mesajı tanımlayın. Chatbot Türkçe cevap veren, kısa ve anlaşılır açıklamalar yapan bir asistan gibi davranmalıdır.
6. Model parametrelerini kullanın. temperature, top_p ve max_tokens değerlerini kod içinde açıkça belirtin.
7. Modelden gelen cevabı terminalde kullanıcı dostu bir formatta yazdırın.

Not

Final ödevinde amaç, Gemma modelini sadece çalıştırmak değil; kullanılabilir, anlaşılır, hata durumlarını yöneten ve öğrencinin kendi kod akışını yansıtan bir chatbot uygulaması geliştirmektir.